

DETECTIA ȘI RECUNOAȘTEREA PLĂCUȚELOR DE ÎNMATRICULARE

Baba Alexandru-Ionut
1407B

I. INTRODUCERE

Recunoașterea automată a numerelor de înmatriculare este o sarcină dificilă și importantă care este folosită în gestionarea traficului, supravegherea digitală a securității, recunoașterea vehiculelor și gestionarea parcarilor în marile orașe. Această sarcină este o problemă complexă din cauza multor factori, care includ, dar nu se limitează la: imagini neclare, condiții de iluminare slabă, variabilitatea numerelor de înmatriculare (inclusiv caractere speciale, cum ar fi logogramele din China și Japonia), impact fizic (deformări) și condiții meteorologice.

Aceste provocări fac ca recunoașterea automată a numerelor de înmatriculare să fie o sarcină complexă care necesită tehnici avansate de vizualizare computerizată și învățare automată pentru a aborda cu succes condițiile nefavorabile și variațiile în numerele de înmatriculare ale vehiculelor.

II. IMPORTANȚĂ

Recunoașterea numerelor de înmatriculare este importantă din mai multe motive:

- Gestionarea traficului: ALPR (Automatic License Plate Recognition) joacă un rol crucial în monitorizarea și gestionarea traficului rutier. Aceasta poate fi utilizată pentru a detecta vehiculele care încalcă regulile de circulație, inclusiv depășirea limitelor de viteză, trecerea pe culoarea roșie sau conducerea cu permisul suspendat. Prin urmare, ajută la îmbunătățirea siguranței rutiere și la fluidizarea traficului.
- Securitatea publică: ALPR este folosit în supravegherea digitală pentru a identifica vehiculele suspecte sau pentru a ajuta la investigarea infracțiunilor. Aceasta poate fi utilă pentru urmărirea vehiculelor implicate în infracțiuni, pentru identificarea vehiculelor

furate sau pentru prevenirea activităților ilegale.

- Gestionarea parcarilor: În orașele mari, gestionarea parcarilor poate fi o provocare majoră. Recunoașterea numerelor de înmatriculare poate fi utilizată pentru monitorizarea și administrarea parcarilor. Aceasta poate ajuta la identificarea vehiculelor care parchează ilegal sau la gestionarea sistemelor de plată automată a parcarii.
- Recunoașterea vehiculelor: ALPR este folosită pentru a recunoaște și identifica vehiculele în scopuri diverse, cum ar fi înregistrarea vehiculelor la trecerea prin punctele de control, urmărirea flotelor de vehicule comerciale sau pentru administrarea parcurilor auto.
- Contribuție la siguranța publică: Prin identificarea vehiculelor implicate în infracțiuni sau căutarea vehiculelor asociate cu alerte de securitate, ALPR poate contribui la asigurarea siguranței publice și la reducerea riscurilor.
- Eficiență operațională: Utilizarea ALPR în diferite domenii, cum ar fi logistică sau transport, poate duce la creșterea eficienței operaționale și la economii de timp și resurse.

În ansamblu, recunoașterea numerelor de înmatriculare este importantă pentru îmbunătățirea siguranței, a securității și a eficienței în numeroase domenii, contribuind la gestionarea mai bună a orașelor și a infrastructurii rutiere.

III. STATE-OF-THE-ART & RELATED WORK

- License Plate Detection and Recognition in Unconstrained Scenarios

[License Plate Detection and Recognition in Unconstrained Scenarios | Papers With Code](#)

- Accurate, Data-Efficient, Unconstrained Text Recognition with Convolutional Neural Networks

[Accurate, Data-Efficient, Unconstrained Text Recognition with Convolutional Neural Networks | Papers With Code](#)

- Practical License Plate Recognition in Unconstrained Surveillance Systems with Adversarial Super-Resolution

[Practical License Plate Recognition in Unconstrained Surveillance Systems with Adversarial Super-Resolution | Papers With Code](#)

- On the Cross-dataset Generalization in License Plate Recognition

[On the Cross-dataset Generalization in License Plate Recognition | Papers With Code](#)

- LPRNet: License Plate Recognition via Deep Neural Networks

[LPRNet: License Plate Recognition via Deep Neural Networks | Papers With Code](#)

- Vehicle and License Plate Recognition with Novel Dataset for Toll Collection

[Vehicle and License Plate Recognition with Novel Dataset for Toll Collection | Papers With Code](#)

IV. SOLUȚII COMERCIALE

- OpenALPR
[OpenALPR - Automatic License Plate Recognition](#)
- Plate Recognizer
[Automatic License Plate Recognition - High Accuracy ALPR \(platerecognizer.com\)](#)

V. DESCRIEREA METODEI

Ce face programul:

Acest program este conceput pentru a detecta și recunoaște plăcuțele de înmatriculare din imagini folosind un model YOLO pre-antrenat pentru detectarea obiectelor și biblioteca EasyOCR pentru recunoașterea textului din plăcuțe. Rezultatele sunt afișate într-o serie de imagini, inclusiv imaginea originală cu detecțiile și textul recunoscut.

Cum funcționează:

1. Deschiderea imaginii: Programul începe prin deschiderea primei imaginii din fișierul pe care utilizatorul îl specifică. Această imagine poate conține diverse obiecte sau elemente de interes. În cazul nostru este folosit pentru a extrage numere de înmatriculare de pe mașini.
2. Pregătirea imaginii: Înainte de a încerca să identifice obiectele, programul "pregătește" imaginea. Face acest lucru prin preprocesarea imaginii pentru a o ajusta la cerințele modelului YOLO.
3. Detecția obiectelor: Se realizează detecția obiectelor din imagine folosind modelul YOLO.
4. Stocarea informațiilor: Se stochează informații despre detecțiile, cum ar fi coordonatele casetei delimitatoare (bounding box), clasa detectată și scorul confidenței.
5. Eliminarea rezultatelor nedorite: Se aplică algoritmul Non-Maximum Suppression (NMS) pentru a elimina detecțiile duplicate și cele cu scoruri scăzute.
6. Recunoașterea textului: Se utilizează EasyOCR pentru a recunoaște textul din plăcuța de înmatriculare (numerele de înmatriculare) din fiecare casetă delimitatoare detectată.


7. Afișarea imaginilor; Se afișează imaginea originală cu casete delimitatoare și textul recunoscut pe ea precum și imaginile prelucrate în niveluri de gri și binare pentru a facilita recunoașterea textului.

REZULTATE

Rezultatele așteptate de la acest program ar trebui să fie următoarele:

1. Detectarea casetelor delimitatoare (bounding box) pentru plăcuțele de înmatriculare din imaginile din directorul de intrare.
2. Recunoașterea textului (numărul de înmatriculare) din fiecare casetă delimitatoare detectată.
3. Afișarea imaginii originale cu casetele delimitatoare și textul recunoscut pe aceasta.
4. Afișarea separată a plăcuței de înmatriculare detectate.
5. Afișarea imaginilor prelucrate în niveluri de gri și binare pentru a facilita recunoașterea textului din plăcuța de înmatriculare.

Rezultatele exacte pot varia în funcție de calitatea imaginilor din directorul de intrare și de performanța modelului YOLO și a bibliotecii EasyOCR. Cu toate acestea, în general, ați putea aștepta ca programul să detecteze și să recunoască cu succes plăcuțele de înmatriculare din imagini bine iluminate și clare, cu text bine definit. Cu toate acestea, performanța poate scădea în cazul imaginilor cu iluminare slabă, distorsiuni sau text ilegibil. Este important să ajustați și să calibrați parametrii programului și să asigurați că aveți setările potrivite pentru calitatea imaginilor pe care le utilizați.



VI. CONCLUZII

- Programul utilizează un model YOLO pre-antrenat pentru a detecta obiecte în imagini, în special plăcuțe de înmatriculare. Performanța acestui aspect depinde în mare măsură de calitatea modelului și de setările folosite pentru detectare. Pentru a obține cele mai bune rezultate, poate fi necesar să ajustăm sau să îmbunătățim modelul și parametrii acestuia.
- Programul utilizează biblioteca EasyOCR pentru a recunoaște textul din plăcuțele de înmatriculare detectate. Performanța acestei etape depinde de calitatea imaginilor și de claritatea textului din plăcuțele de înmatriculare. Rezultatele pot varia în funcție de font, dimensiune, iluminare și distorsiuni ale textului.
- Programul afișează imaginile originale, plăcuțele de înmatriculare detectate și imaginile prelucrate pentru a facilita recunoașterea textului. Acest lucru poate ajuta utilizatorii să evalueze cu ușurință performanța programului și să verifice corectitudinea recunoașterii textului.
- Programul poate fi îmbunătățit prin ajustarea parametrilor și a setărilor pentru detecție și recunoaștere text, precum și prin utilizarea unor modele YOLO mai avansate sau prin antrenarea unui model personalizat pe date specifice. De asemenea, pot fi luate în considerare tehnicile de preprocesare și postprocesare pentru îmbunătățirea performanței.

VII. REFERENCES

[1] C. N. E. Anagnostopoulos, I. E. Anagnostopoulos, I. D. Psoroulas, V. Loumos, and E. Kayafas, "License Plate Recognition From Still Images and Video Sequences: A Survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 9, no. 3, pp. 377–391, Sep. 2008.

[2] H. Li and C. Shen, "Reading Car License Plates Using Deep Convolutional Neural Networks and LSTMs," *arXiv:1601.05610 [cs]*, Jan. 2016, *arXiv: 1601.05610*. 2,

[3] A. Graves, *Supervised Sequence Labelling with Recurrent Neural Networks*, 2012th ed. Heidelberg ; New York: Springer,

Feb. 2012.

[4] A. Graves, S. Fernandez, F. Gomez, and J. Schmidhuber, "Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks," in *Proceedings of the 23rd international conference on Machine learning*. ACM, 2006, pp. 369–376. 2, 3

[5] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, Nov. 1997. 2

[6] T. K. Cheang, Y. S. Chong, and Y. H. Tay, "Segmentation Free Vehicle License Plate Recognition using ConvNetRNN," *arXiv:1701.06439 [cs]*, Jan. 2017, *arXiv: 1701.06439*. 2

[7] V. Jain, Z. Sasindran, A. Rajagopal, S. Biswas, H. S. Bharadwaj, and K. R. Ramakrishnan, "Deep Automatic License Plate Recognition System," in *Proceedings of the Tenth Indian Conference on Computer Vision, Graphics and Image Processing*, ser. *ICVGIP '16*. New York, NY, USA: ACM, 2016, pp. 6:1–6:8. 2

[8] M. Jaderberg, K. Simonyan, A. Zisserman, and K. Kavukcuoglu, "Spatial Transformer Networks," *arXiv:1506.02025 [cs]*, Jun. 2015, *arXiv: 1506.02025*. 2, 3

[9] H. Li, P. Wang, and C. Shen, "Towards End-to-End Car License Plates Detection and Recognition with Deep Neural Networks," *ArXiv e-prints*, Sep. 2017. 2

[10] X. Wang, Z. Man, M. You, and C. Shen, "Adversarial Generation of Training Examples: Applications to Moving Vehicle License Plate Recognition," *ArXiv e-prints*, Jul. 2017.

[11] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative Adversarial Networks," *ArXiv e-prints*, Jun. 2014.

[12] W. Liu, A. Rabinovich, and A. C. Berg, "ParseNet: Looking Wider to See Better," *arXiv:1506.04579 [cs]*, Jun. 2015, *arXiv: 1506.04579*. 2, 3

[13] F. N. Iandola, S. Han, M. W. Moskewicz, K. Ashraf, W. J. Dally, and K. Keutzer, "SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5mb model size," *arXiv:1602.07360 [cs]*, Feb. 2016, *arXiv: 1602.07360*. 2, 3

[14] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, "Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning," *arXiv:1602.07261 [cs]*, Feb. 2016, *arXiv: 1602.07261*. 2, 3

[15] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going Deeper with Convolutions," *arXiv:1409.4842 [cs]*, Sep. 2014, *arXiv: 1409.4842*. 2, 3

[16] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the Inception Architecture for Computer Vision," *arXiv:1512.00567 [cs]*, Dec. 2015, *arXiv: 1512.00567*. 2, 3

[17] S. Ioffe and C. Szegedy, “Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift,” arXiv:1502.03167 [cs], Feb. 2015, arXiv: 1502.03167. 2, 3

[18] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A Simple Way to Prevent Neural Networks from Overfitting,” J. Mach. Learn. Res., vol. 15, no. 1, pp. 1929–1958, Jan. 2014.